Modelos de pronóstico temporal en finanzas: una comparación entre enfoques no lineales clásicos, deep learning y métodos bayesianos

Gustavo W.

28 de agosto de 2026

Índice

1 Introducción **2**

2 Revisión de literatura **3**
2.1 Modelos de umbral y de cambio de régimen . . . 3
2.2 Deep learning y aprendizaje de máquina en finanzas . . . 3
2.3 Métodos bayesianos . . . 3
2.4 Síntesis crítica . . . 3

3 Metodología **3**
3.1 Modelos . . . 3
3.1.1 Autorregresivo de umbral (TAR / SETAR) . . . 3
3.1.2 Autorregresivo con cambio de régimen markoviano (MS-AR) . . . 3
3.1.3 Modelo bayesiano autorregresivo . . . 4
3.1.4 Aprendizaje de máquina y deep learning . . . 4
3.2 Diseño del experimento Monte Carlo . . . 4
3.3 Evaluación . . . 5

4 Resultados **5**
4.1 Anexo empírico . . . 8

5 Discusión **8**

6 Conclusiones e implicaciones **8**

Referencias **8**

Estado del documento. Esqueleto de trabajo. La metodología está redactada en su versión definitiva; las secciones de resultados leen automáticamente los agregados de la simulación desde `resultados/`. Mientras solo exista la corrida piloto, las cifras son ilustrativas y no deben citarse.

1 Introducción

Motivación. El pronóstico de series financieras y macro-financieras enfrenta tres rasgos que los modelos lineales gaussianos no capturan: no linealidad en la dinámica condicional, cambios de régimen, y colas gruesas con volatilidad agrupada. La literatura ha respondido con tres programas de investigación que han avanzado en paralelo y rara vez se comparan bajo un protocolo común: (i) los modelos no lineales clásicos de umbral y de cambio de régimen (Tong 1990; Hamilton 1989); (ii) el aprendizaje profundo y el aprendizaje de máquina; y (iii) los métodos bayesianos de series de tiempo.

Contribución. Este artículo aporta tres elementos:

1. Un **experimento Monte Carlo con procesos generadores conocidos** que aísla las condiciones bajo las cuales cada familia domina. A diferencia de las comparaciones basadas únicamente en datos reales, aquí se conoce la verdad y es posible separar el sesgo de especificación de la varianza de estimación.
2. Un tratamiento explícito y separado de los **mecanismos de umbral**: umbral autoexcitado, umbral definido por una **variable continua exógena**, y umbral definido por una **variable categórica observable**. Esta distinción, poco frecuente en la literatura comparativa, es la que conecta el ejercicio econométrico con la práctica de gestión de riesgo, donde el régimen a veces se observa y a veces debe inferirse.
3. Una evaluación que va más allá del error puntual, incorporando **calibración de la densidad predictiva** (CRPS, cobertura, pérdida pinball) y **costo computacional**, y que se cierra con una aplicación a ocho series colombianas e internacionales de frecuencias distintas.

Preguntas de investigación. (P1) ¿En qué contextos —tipo de proceso, frecuencia, ruido, presencia y forma de los regímenes— domina cada familia? (P2) ¿Cómo se comparan en interpretabilidad, costo y cuantificación de incertidumbre? (P3) ¿Qué implica esto para riesgo, asignación de activos y diseño de estrategias?

2 Revisión de literatura

2.1 Modelos de umbral y de cambio de régimen

2.2 Deep learning y aprendizaje de máquina en finanzas

2.3 Métodos bayesianos

2.4 Síntesis crítica

3 Metodología

3.1 Modelos

3.1.1 Autorregresivo de umbral (TAR / SETAR)

Sea q_t la variable de umbral y r el valor de corte. El modelo TAR de dos regímenes con orden autorregresivo p es

$$y_t \;=\; \begin{cases} \phi_0^{(1)} + \sum_{i=1}^{p} \phi_i^{(1)} y_{t-i} + \sigma_1 \varepsilon_t, & q_t \le r, \\ \phi_0^{(2)} + \sum_{i=1}^{p} \phi_i^{(2)} y_{t-i} + \sigma_2 \varepsilon_t, & q_t > r, \end{cases} \qquad \varepsilon_t \sim \text{iid}(0,1).$$

Se consideran tres especificaciones de q_t:

- **Autoexcitada (SETAR):** $q_t = y_{t-d}$, con retardo d estimado.
- **Continua exógena:** $q_t = z_{t-d}$, con z_t observable (en la aplicación, el spread EMBI de Colombia).
- **Categórica observable:** el régimen no se obtiene de un corte sino de un indicador $s_t \in \{1, \ldots, K\}$ (en la aplicación, la fase del ciclo de política monetaria).

La estimación es por mínimos cuadrados condicionales: para cada candidato r de una rejilla sobre los cuantiles $[0.15, 0.85]$ de q_t se estima por MCO cada régimen y se elige el r que minimiza la suma de cuadrados residual; p y d se seleccionan por BIC. La densidad predictiva se obtiene simulando B trayectorias con remuestreo de los residuos específicos de cada régimen, lo que evita imponer normalidad y respeta la heterocedasticidad entre regímenes.

3.1.2 Autorregresivo con cambio de régimen markoviano (MS-AR)

$$y_t = c_{S_t} + \sum_{i=1}^{p} \phi_{i,S_t}\, y_{t-i} + \sigma_{S_t} \varepsilon_t, \qquad \Pr(S_t = j \mid S_{t-1} = i) = p_{ij},$$

con S_t latente y matriz de transición $P = [p_{ij}]$ de primer orden (Hamilton 1989, 1994). La verosimilitud se evalúa con el filtro de Hamilton,

$$\xi_{t|t} \;=\; \frac{(P' \xi_{t-1|t-1}) \odot \eta_t}{\mathbf{1}' \big[(P' \xi_{t-1|t-1}) \odot \eta_t \big]}, \qquad \eta_t(j) = f(y_t \mid S_t = j, \mathcal{F}_{t-1}),$$

y se maximiza numéricamente; P se parametriza con un logit multinomial por filas para garantizar que sus entradas sean positivas y sumen uno. El número de regímenes $K \in \{2, 3\}$ se elige por BIC. El pronóstico a h pasos se obtiene simulando trayectorias del régimen desde $\xi_{T|T}$, de modo que la densidad predictiva es una mezcla y no una normal.

La comparación TAR-categórico frente a MS-AR es informativa por construcción: en el DGP D8 el régimen es el mismo objeto, observable para el primero y latente para el segundo, de modo que la diferencia de desempeño mide el **valor de información** del indicador de régimen.

3.1.3 Modelo bayesiano autorregresivo

$$y_t = \beta' x_t + \varepsilon_t, \quad \varepsilon_t \sim N(0, \sigma^2), \qquad \beta \mid \sigma^2 \sim N(b_0,\ \sigma^2 V_0), \quad \sigma^2 \sim \mathcal{IG}(a_0, d_0),$$

con $x_t = (1, y_{t-1}, \ldots, y_{t-p})'$ y un prior de encogimiento tipo Minnesota: media de paseo aleatorio en el primer rezago y varianza $(\lambda/i)^2$ en el rezago i. La conjugación permite obtener la posterior en forma cerrada y simular la densidad predictiva exacta sin MCMC, lo que hace viable repetirla miles de veces en el experimento. En la aplicación empírica se amplía a un BSTS con componente de nivel local y a un BVAR para el bloque macro-financiero (Frühwirth-Schnatter 2006).

3.1.4 Aprendizaje de máquina y deep learning

Ensambles de árboles sobre una ventana de $p = 12$ rezagos, con pronóstico recursivo. La dispersión predictiva se calibra sobre un **holdout temporal** (último 20 % de la muestra de entrenamiento) y no sobre los residuos in-sample, que en un ensamble de árboles están sesgados a la baja y producirían intervalos espurios. Como representante de red neuronal en el experimento se usa una red autorregresiva feed-forward; en la aplicación empírica se incorporan LSTM, GRU, CNN-LSTM y arquitecturas con atención.

3.2 Diseño del experimento Monte Carlo

Diez procesos generadores, dos tamaños muestrales ($T \in \{250, 1000\}$), dos niveles de ruido ($\sigma \in \{0.5, 2\}$) y tres horizontes ($h \in \{1, 5, 10\}$). El detalle completo de parámetros está en `protocolo/protocolo_simulacion.md`.

Cuadro 1: Procesos generadores del experimento.

ID	Proceso	Bloque
D1a	AR(1), phi=0.5	Lineal
D1b	AR(1), phi=0.9	Lineal
D2	ARMA(1,1)	Lineal
D3	ARIMA(1,1,1)	Integrado
D4	ARIMA(1,1,0)	Integrado
D5	ARIMA(0,0,1)	Lineal
D6a	SETAR (delta baja)	Umbral autoexcitado

ID	Proceso	Bloque
D6b	SETAR (delta alta)	Umbral autoexcitado
D7	TAR con umbral continuo exógeno	Umbral continuo
D8	TAR con umbral categórico observable	Umbral categórico

3.3 Evaluación

Partición 70/15/15 con origen móvil de ventana expansiva. Métricas: RMSE, MAE, MASE, U de Theil; CRPS y pérdida pinball para la densidad predictiva; PICP y MPIW para los intervalos al 80 % y 95 %. Contraste de superioridad predictiva mediante Diebold–Mariano con corrección de muestra pequeña, tomando ARIMA como pivote, y reporte de la proporción de rechazos por celda. Se registra el tiempo de estimación y pronóstico de cada modelo.

4 Resultados

Cuadro 2: RMSE relativo al benchmark ARIMA a un paso (valores < 1 indican mejor desempeño que ARIMA). Columnas: M0 naive, M1 ARIMA, M2 SETAR autoexcitado, M2z TAR con umbral continuo exógeno, M2s TAR con umbral categórico observable, M3 MS-AR, M4 AR(p) bayesiano, M5 ensamble de árboles, M6 red neuronal autorregresiva.

DGP	Proceso	M0	M1	M2	M2z	M2s	M3	M4	M5	M6	Mejor
D1a	AR(1) phi=0.5	1.069	1	0.993	NA	NA	0.987	0.994	1.091	1.085	MS-AR
D1b	AR(1) phi=0.9	1.000	1	1.019	NA	NA	1.000	0.977	1.055	1.015	Bayesiano
D2	ARMA(1,1)	1.078	1	0.911	NA	NA	1.024	0.975	1.170	1.002	SETAR
D3	ARIMA(1,1,1)	1.035	1	1.019	NA	NA	0.872	0.876	1.059	1.005	MS-AR
D4	ARIMA(1,1,0)	1.241	1	1.058	NA	NA	1.022	1.052	1.074	1.038	ARIMA
D5	ARIMA(0,0,1)	1.339	1	1.068	NA	NA	1.079	1.058	1.192	1.083	ARIMA
D6a	SETAR delta baja	1.097	1	1.000	NA	NA	0.999	1.010	1.026	0.986	Red neuronal
D6b	SETAR delta alta	1.010	1	0.996	NA	NA	0.994	1.007	1.239	1.059	MS-AR
D7	TAR umbral continuo	1.281	1	1.107	1.035	NA	1.039	1.066	1.311	1.159	ARIMA
D8	TAR umbral categórico	1.136	1	1.033	NA	0.95	0.983	0.998	1.012	1.237	TAR umbral s

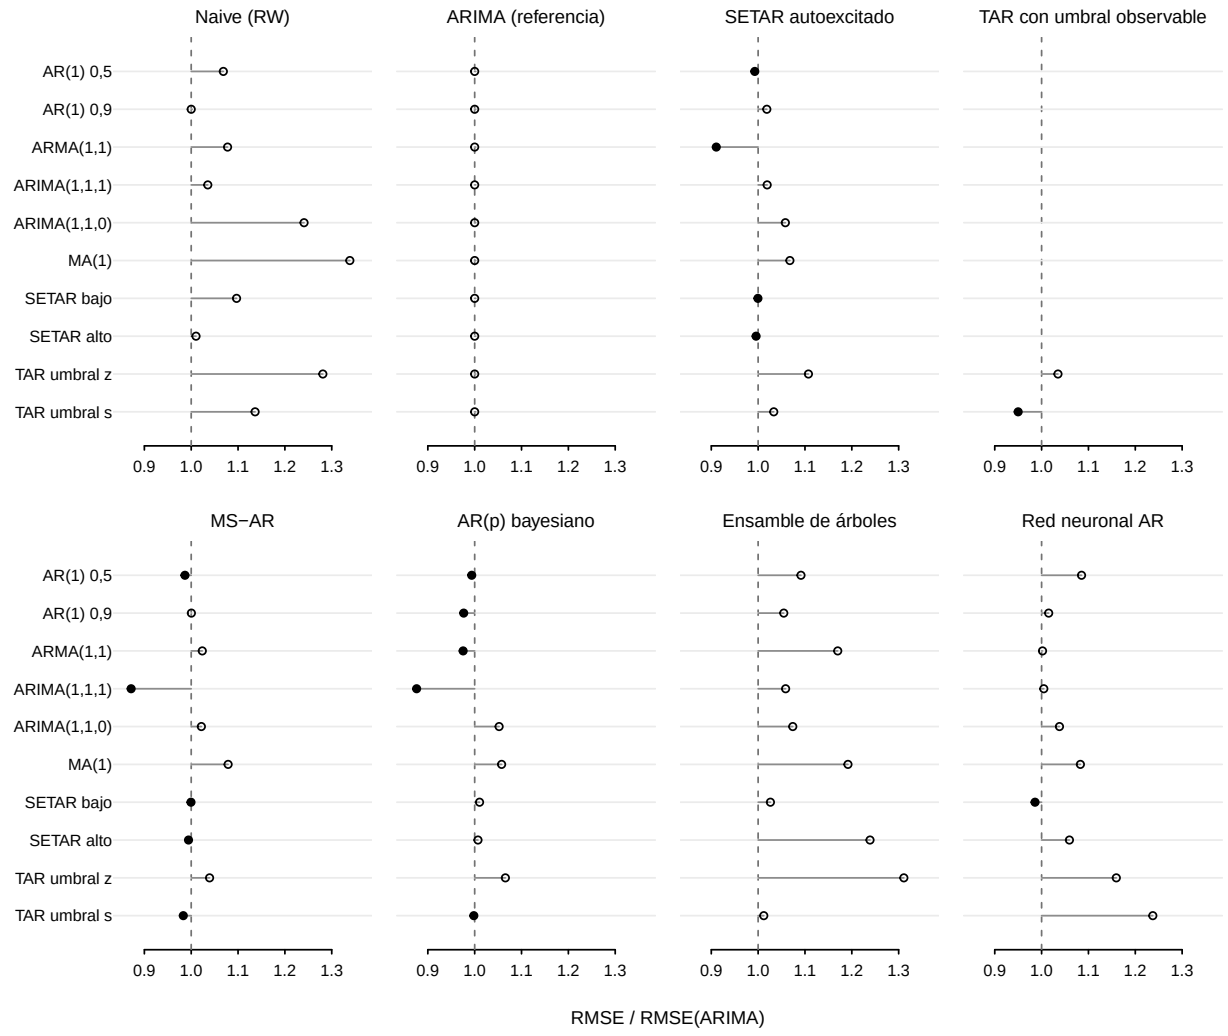


Figura 1: RMSE relativo a ARIMA por proceso generador. Un panel por modelo; la línea punteada marca la paridad con ARIMA. Punto lleno: el modelo supera a ARIMA en esa celda.

Cuadro 3: Proporción de réplicas en que el modelo supera significativamente a ARIMA (Diebold-Mariano con corrección de muestra pequeña, 5 %). Con 15 orígenes por réplica la prueba tiene poca potencia; la corrida definitiva incorpora además un DM agrupado.

DGP	M0	M2	M2z	M2s	M3	M4	M5	M6
D1a	0	0	NA	NA	0	0.0	0	0
D1b	0	0	NA	NA	0	0.2	0	0
D2	0	0	NA	NA	0	0.0	0	0
D3	0	0	NA	NA	0	0.0	0	0
D4	0	0	NA	NA	0	0.0	0	0
D5	0	0	NA	NA	0	0.0	0	0
D6a	0	0	NA	NA	0	0.0	0	0
D6b	0	0	NA	NA	0	0.0	0	0
D7	0	0	0	NA	0	0.0	0	0
D8	0	0	NA	0	0	0.0	0	0

Cuadro 4: Calibración de la densidad predictiva y costo computacional (mediana entre las diez celdas, h = 1). La cobertura nominal es 0,80 y 0,95: valores por debajo indican intervalos demasiado angostos.

Modelo	PICP80	PICP95	CRPS	MPIW95	Segundos	RMSE rel.
TAR umbral categórico (s)	0.760	0.933	0.561	4.233	0.014	0.950
MS-AR	0.800	0.940	0.580	3.975	0.155	1.000
ARIMA (auto)	0.807	0.953	0.579	3.903	0.095	1.000
AR(p) bayesiano	0.800	0.960	0.584	4.016	0.012	1.003
SETAR autoexcitado	0.773	0.933	0.586	3.921	0.038	1.019
TAR umbral continuo (z)	0.653	0.880	0.556	3.960	0.043	1.035
Red neuronal AR	0.687	0.873	0.607	3.636	1.850	1.049
ML de árboles	0.773	0.947	0.645	4.678	0.143	1.083
Naive (RW)	0.793	0.933	0.656	4.425	0.005	1.087

4.1 Anexo empírico

5 Discusión

6 Conclusiones e implicaciones

Referencias

Frühwirth-Schnatter, Sylvia. 2006. *Finite Mixture and Markov Switching Models*. New York: Springer.

Hamilton, James D. 1989. «A New Approach to the Economic Analysis of Nonstationary Time Series and the Business Cycle». *Econometrica* 57 (2): 357-84.

———. 1994. *Time Series Analysis*. Princeton, NJ: Princeton University Press.

Tong, Howell. 1990. *Non-Linear Time Series: A Dynamical System Approach*. Oxford: Oxford University Press.